

Família Bode

Modelos de linguagem para o português brasileiro



João Victor
Lucas Rapozo
Antonieli Magalhães



Problema e objetivo do artigo

- Modelos com treinamento concentrado em inglês podem interpretar mal expressões e contextos do português brasileiro.
- O artigo investiga a adaptação de modelos de pesos abertos por **ajuste fino** com instruções em português.
- **Pergunta central da síntese:** em quais modelos e tarefas essa adaptação melhora o desempenho?

Fonte: Paiola et al. (2025), seção 1.

A proposta: uma família de modelos adaptados

- **35 variantes catalogadas**, incluindo versões com adaptadores incorporados e formatos de distribuição.
- Bases: LLaMA, Gemma, Phi, Mistral, InternLM, Qwen e Zephyr.
- Diferentes portes e estratégias de ajuste permitem comparar desempenho e escolhas de adaptação.
- Contribuição: disponibilização dos modelos e avaliação comparativa em português brasileiro.

Fonte: Paiola et al. (2025), seções 5 e 5.8; Tabela 1.

Dados e estratégias de ajuste

Dados de instrução

- **Alpaca:** 52 mil exemplos traduzidos para português.
- **UltraAlpaca:** combina instruções, conversas, código e matemática de diferentes conjuntos.

Como adaptar

- **Full:** atualiza todos os pesos.
- **LoRA:** treina adaptadores, mantendo os pesos-base fixos.
- **QLoRA:** usa uma base quantizada com adaptadores, reduzindo a memória necessária.

Fonte: Paiola et al. (2025), seções 3.1, 4 e 6.1.

Avaliação: nove tarefas em português

Conjunto de tarefas	O que avalia
ENEM, BLUEX e OAB	Questões de provas; acurácia, com 3 exemplos no prompt.
ASSIN2 RTE/STS; FAQUAD NLI	Inferência e similaridade; F1 macro ou correlação de Pearson, com 15 exemplos.
HateBR; PT Hate Speech; tweetSentBR	Ofensividade, discurso de ódio e sentimento; F1 macro, com 25 exemplos.

Comparação principal: modelo adaptado versus sua respectiva base, no Open PT-LLM Leaderboard.

Fonte: Paiola et al. (2025), seção 6.2; a média agregada combina métricas diferentes.

Resultados: ganhos em parte dos modelos

Recorte da Tabela 2 — pontuação média reportada

Base → variante Bode	Base	Bode	Δ
Gemma-7B-it → gembode-7b-it	49,61	60,60	+10,99
Phi-2 → Phi-Bode	36,52	43,59	+7,07
Mistral-7B → QLoRA/UltraAlpaca	61,13	65,35	+4,22
InternLM2-chat-20B → ChatBode	70,59	71,68	+1,09

ChatBode-20B tem a maior média entre os Bode apresentados, mas o maior ganho deste recorte é do Gemma-7B-it.

Fonte: Paiola et al. (2025), Tabela 2; diferenças em pontos do escore agregado, não em porcentagem de ganho.

O ajuste fino também pode piorar o resultado

Base → variante Bode	Base	Bode	Δ
LLaMA-3.1-8B-Instruct → Full	71,24	69,78	−1,46
Phi-3-mini → UltraAlpaca	66,41	60,69	−5,72
Gemma-2B → QLoRA/UltraAlpaca	44,07	31,19	−12,88

- O benefício depende da base, dos dados, do ajuste e da tarefa.
- Os autores sugerem sobreajuste ou perda de conhecimento como explicações possíveis; não demonstram uma causa única.

Fonte: Paiola et al. (2025), Tabela 2; seções 7.2 e 7.3.

Um exemplo de interpretação cultural

Expressão analisada no artigo

“vergonha alheia”

- No exemplo, **InternLM2** classifica o sentimento como neutro.
- **ChatBode** identifica o sentimento negativo, coerente com o constrangimento expresso.
- O caso ilustra uma melhora de interpretação; exemplos selecionados não comprovam domínio cultural geral.

Fonte: Paiola et al. (2025), seção 7.5.

Limitações e leitura crítica

- **Média heterogênea:** acurácia, F1 macro e correlação de Pearson medem aspectos diferentes.
- **Reprodutibilidade parcial:** nem todos os registros de treinamento foram preservados; há hiperparâmetros representativos.
- **Vieses dos dados:** tradução e geração sintética podem carregar referências culturais e vieses das fontes.
- **Alcance da evidência:** a análise cultural adicional usa apenas sete questões selecionadas do ENEM.

Fonte: Paiola et al. (2025), seções 6.1, 6.2, 7.5.1 e 7.7; síntese crítica da equipe.

Síntese do artigo

- A família Bode oferece modelos adaptados e uma comparação ampla de alternativas para português brasileiro.
- Há ganhos relevantes, mas **o ajuste fino não garante melhoria**: bases fortes também podem perder desempenho.
- Nossa leitura: a escolha deve considerar **a tarefa de interesse e a comparação com a base**, além da média geral.

Direção futura apontada pelos autores: dados de instrução de qualidade produzidos originalmente em português.

Fonte: Paiola et al. (2025), seções 7 e 8.

Artigo de referência

The Bode Family of Large Language Models: Investigating the Frontiers of LLMs in Brazilian Portuguese

Pedro Henrique Paiola; Gabriel Lino Garcia; João Vitor Mariano Correia; João Renato Ribeiro Manesco; Ana Lara Alves Garcia; João Paulo Papa.

Journal of the Brazilian Computer Society, v. 31, n. 1, 2025.

DOI: 10.5753/jbcs.2025.5812

Todos os resultados apresentados são os reportados no artigo de 2025. Os nomes abreviados nas tabelas identificam os pares da Tabela 2.