Distributed Representations of Sentences and Documents

João Victor

Lucas Rapozo

Antoniel Magalhães





O problema: representar textos em tamanho fixo

Limitações das abordagens clássicas (Bag-of-Words e N-gramas)

$$\text{dist}(\texttt{powerful}, \texttt{strong}) = \text{dist}(\texttt{powerful}, \texttt{Paris})$$

- Algoritmos como regressão logística e K-means exigem vetores de tamanho fixo na entrada.
- **Bag-of-Words (BoW):** perde a ordem das palavras e ignora a distância semântica entre os termos.
- **Média de vetores e árvores sintáticas:** a média perde a ordem das palavras; modelos baseados em *parsing* ficam restritos a sentenças isoladas.

Fonte: Le & Mikolov (ICML 2014), seção 1.

Proposta: Paragraph Vector (Doc2Vec)

- Algoritmo não supervisionado que aprende vetores densos de tamanho fixo para textos de comprimento variável (frases, parágrafos ou documentos).
- **Inspiração no Word2Vec:** vetores inicializados aleatoriamente capturam semântica ao contribuírem para prever a próxima palavra no contexto.
- **Memória distribuída:** cada documento recebe um vetor exclusivo na matriz D, enquanto os vetores de palavras na matriz W são compartilhados no corpus.
- O treinamento utiliza descida de gradiente estocástica (SGD) com *hierarchical softmax* baseada em árvore binária de Huffman.

Fonte: Le & Mikolov (ICML 2014), seções 1, 2.1 e 2.2.

Arquitetura 1: Memória Distribuída (PV-DM)

Fluxo de predição no PV-DM

Entrada:
ID do Parágrafo $(D) + [\texttt{the}, \texttt{cat}, \texttt{sat}](W)$

$\Downarrow$ *Concatenar ou promediar (h)*

Classificador Softmax: $y = b + Uh$

$\Downarrow$

Saída prevista: `on`

1. O token do parágrafo atua como memória do tópico global que falta na janela local.
2. O vetor D é reutilizado em todas as janelas deslizantes amostradas do mesmo texto.
3. Total de parâmetros (sem o softmax): $N \times p + M \times q$, com atualizações esparsas.

Fonte: Le & Mikolov (ICML 2014), seção 2.2, Equação 1 e Figura 2.

Arquitetura 2 (PV-DBOW) e Etapa de Inferência

PV-DBOW (Bag of Words Distribuído)

- Ignora palavras na entrada e prevê palavras sorteadas da janela usando apenas o vetor D.
- Análogo ao *Skip-gram*; exige menos armazenamento por não manter a matriz W.

Inferência para novos textos

- Em documentos inéditos, congelam-se os vetores de palavras W e os pesos U, b.
- Adiciona-se uma coluna em D, otimizada via gradiente até convergir.

Recomendação prática: concatenar os vetores do PV-DM (400 dimensões) e do PV-DBOW (400 dimensões) para alimentar o classificador final.

Fonte: Le & Mikolov (ICML 2014), seções 2.2, 2.3 e Figura 3.

Evidência 1: Análise de Sentimento em Sentenças (SST)

Desempenho no Stanford Sentiment Treebank (11.855 sentenças)

Modelo	Taxa de erro (Binário)	Taxa de erro (5 classes)
Naïve Bayes / SVM (Socher et al., 2013b)	18,2% / 20,6%	59,0% / 59,3%
Média de Vetores de Palavras	19,9%	67,3%
Recursive Neural Tensor Network (RNTN)	14,6%	54,3%
Paragraph Vector (PV-DM + PV-DBOW)	**12,2%**	**51,3%**

- Redução absoluta de **2,4 pontos percentuais** no erro binário (16% de melhoria relativa) sobre a RNTN, sem depender de árvores sintáticas (*parsing*).

Fonte: Le & Mikolov (ICML 2014), seção 3.1 e Tabela 1; janela ótima de tamanho 8 com regressão logística.

Evidência 2: Documentos de Múltiplas Sentenças (IMDB)

Classificação em 100.000 avaliações longas (25k treino, 25k teste, 50k sem rótulo)

Modelo	**Taxa de erro**
Bag-of-Words (bnc) (Maas et al., 2011)	12,20%
WRRBM + Bag-of-Words (bnc) (Dahl et al., 2012)	10,77%
SVM-bi / NBSVM-bi (Wang & Manning, 2012)	10,84% / 8,78%
Paragraph Vector (PV-DM + PV-DBOW)	**7,42%**

- Único método avaliado a romper a barreira de 10% de erro com folga (melhoria relativa de 15% sobre o NBSVM-bi), superando o limite de frase única das redes recursivas.

Fonte: Le & Mikolov (ICML 2014), seção 3.2 e Tabela 2; janela de 10 palavras e rede neural com 50 unidades.

Evidência 3: Recuperação de Informação em Trincas

Identificação de *snippets* da mesma consulta (1 milhão de buscas)

Método de representação	**Taxa de erro na trinca**
Média de Vetores de Palavras (*Vector Averaging*)	10,25%
Bag-of-Words (TF-IDF)	8,10%
Bag-of-Bigrams / Weighted Bag-of-Bigrams (TF-IDF)	7,28% / 5,67%
Paragraph Vector	**3,82%**

- O erro ocorre quando dois resultados da mesma consulta ficam mais distantes entre si do que um parágrafo aleatório de outra busca (melhoria relativa de **32%**).

Fonte: Le & Mikolov (ICML 2014), seção 3.3 e Tabela 3; divisão 80% treino, 10% validação e 10% teste.

Ablações e escolhas de projeto no IMDB

Configuração analisada	Taxa de erro (IMDB)	Impacto observado
PV-DM isolado (com concatenação)	7,63%	Desempenho próximo ao estado da arte sozinho.
PV-DM isolado (com soma/média)	8,06%	Perde informação de ordem das palavras na janela.
Combinação PV-DM + PV-DBOW	**7,42%**	Mais consistente entre diferentes tarefas.

Conclusão e limites da evidência

- O Paragraph Vector supera representações BoW e redes baseadas em árvores sintáticas ao preservar semântica e ordem local em textos de qualquer tamanho.
- O aprendizado não supervisionado permite aproveitar grandes volumes de dados não rotulados (como os 50 mil textos extras no IMDB).
- **Limite de inferência:** ao contrário de um *forward pass* direto, documentos inéditos exigem otimização iterativa por gradiente antes da classificação.
- **Memória e contexto:** a matriz D cresce linearmente com o número de documentos ($N \times p$) e a ordem das palavras é capturada apenas dentro da janela fixa.

Fonte: Le & Mikolov (ICML 2014), seções 2.2, 3.4 e 5; análise crítica da equipe.

Artigo de referência

Distributed Representations of Sentences and Documents

Quoc Le; Tomas Mikolov. Google Inc. *Proceedings of the 31st International Conference on Machine Learning (ICML 2014)*, JMLR: W&CP volume 32, Beijing, China, 2014.

JMLR v32 / arXiv:1405.4053

Síntese baseada no PDF fornecido. Os esquemas e tabelas dos slides reproduzem os modelos descritos nas Figuras 1–3 e os resultados das Tabelas 1–3 do artigo original.