NorBERTo: A ModernBERT Model Trained for Portuguese with 331B Tokens Corpus

João Victor

Lucas Rapozo

Antoniel Magalhães

computação UFBA

computação UFBA

Motivação: LLMs generativos versus Encoders dedicados

A perspectiva de *Right-Sized AI* para o português

Encoders compactos (∼150M–395M) × LLMs generativos de bilhões de parâmetros

- **Limites dos LLMs:** alto custo financeiro e computacional, latência elevada, restrições de privacidade/governança e risco de alucinações.
- **Vantagem dos encoders:** modelos bidirecionais continuam superiores em custo-benefício para classificação, ranqueamento e sistemas de RAG.
- **Defasagem no português:** o BERTimbau foi treinado em apenas 2,68 bilhões de tokens (brWaC) e sem os avanços recentes de arquitetura.

Fonte: Silva et al. (PROPOR 2026), seções 1 e 2.1–2.2.

Contribuição 1: O corpus monolíngue Aurora-PT

Evolução dos corpora abertos em língua portuguesa

Corpus	**Tamanho em disco**	**Quantidade de documentos**
Carolina / brWaC	11 GB / 25 GB	2,11 mi / 3,53 mi
Aroeira / FineWeb-2_Latn-por	100 GB / 257 GB	24,9 mi / 200 mi
GigaVerbo (Tucano)	780 GB	145 mi
Aurora-PT (Silva et al., 2026)	**873 GB**	**275 mi**

- Reúne 9 bases (FineWeb v2 com 90,8% de retenção, mC4 com 46,7%, HPLT 2.0, Aroeira, MOSCAR, Wikipédia, Blogset-br, Aya e CC100).
- Totaliza **331 bilhões de tokens** (referência GPT-2) ou **226 bilhões** no tokenizador próprio.

Fonte: Silva et al. (PROPOR 2026), seções 2.3 e 3.1; Tabelas 1 e 2.

Curadoria de dados e avaliação intrínseca do Aurora-PT

Pipeline de filtragem (DataTrove)

1. **Idioma:** GlotLID (limiar $\geq 0,799$).
2. **Desduplicação:** MinHash com 112 hashes distribuídos em 14 *buckets*.
3. **Heurísticas C4 e FineWeb:** remoção de linhas curtas, código ({}, *Javascript*, *cookies*) e baixa pontuação.

Qualidade lexical e perplexidade

- **Diversidade estável:** TTR mediano de 0,567 e HD-D alinhado aos pares.
- **Composição:** densidade lexical de 0,465 e *stopwords* em 0,350.
- **Menor perplexidade (mGPT):** 20.438 contra 51.199 do GigaVerbo.

Ressalva metodológica: a baixa perplexidade pode refletir sobreposição parcial com dados de treino do mGPT.

Fonte: Silva et al. (PROPOR 2026), seções 3.1 e 4.1; Figuras 1–2 e Tabelas 5–6.

Contribuição 2: Arquitetura do NorBERTo (ModernBERT)

Parâmetro arquitetural	**NorBERTo-base (∼150M)**	**NorBERTo-large (∼395M)**
Vocabulário / Contexto máximo	50.368 / 8.192 tokens	50.368 / 8.192 tokens
Camadas / Dimensão oculta (*Hidden*)	22 / 768	28 / 1.024
Cabeças de atenção / Expansão GLU	12 / 2.304	16 / 5.248
Padrão de	Global na 1ª e a cada 3; Local: 128	Global na 1ª e a cada 3; Local: 128

Treinamento em três fases para extensão de contexto

Divisão dos 226 bilhões de tokens (MLM com mascaramento de 30%)

Configuração	**1. Pré-treino (85%)**	**2. Extensão (12,5%)**	**3. Decay (2,**
Volume de tokens	195B	29B	
Janela máxima de contexto	1.024	8.192	8
Batch size (Base / Large)	4.096 / 4.928	616 / 576	624 /
Taxa de aprendizado (Base / Large)	8e-4 / 5e-4	3e-4 / 5e-5	3e-4 /

- Documentos com mais de 1.024 tokens são reservados para as fases 2 e 3.
- Treinamento concluído em 1 época ($\sim$3 dias) usando 8 GPUs NVIDIA H100 e otimizador Stable AdamW (pesos do *Large* inicializados via *tiling* do *Base*).

Fonte: Silva et al. (PROPOR 2026), seção 3.2 e Tabela 4.

Evidência 1: Inferência e Similaridade no ASSIN 2

Avaliação em 10.000 pares de sentenças (6.500 treino, 500 validação, 2.448 teste)

Modelo	Tamanho	Entailment (F1)	Similaridade (Pearson)
Albertina PT-BR	base	0,8740	0,826
BERTimbau	base / large	0,8833 / 0,8891	0,836 / **0,852**
mmBERT	base	0,8963	0,8212
NorBERTo	base	0,8900	0,736
NorBERTo (seq. class. / cross enc.)	large	**0,9038** / 0,9033	— / 0,766

- **Contraste importante:** lidera em acarretamento textual (90,4% F1), mas fica atrás em similaridade semântica (0,766 vs. 0,852) por ser treinado do zero (*from scratch*), sem herdar checkpoints do inglês.

Fonte: Silva et al. (PROPOR 2026), seção 4.2.1 e Tabela 7.

Evidência 2: Estado da Arte no Benchmark PLUE

Versão traduzida do GLUE para o português (F1-score / Acurácia)

Modelo	Tamanho	MRPC (Paráfrase)	RTE (Inferência)	WNLI (Correferência)
Albertina PT-BR	base	0,8779	0,6462	0,5493
BERTimbau	large (340M)	0,8873	0,7545	0,5634
mmBERT	base	0,9051	0,7582	0,5633
NorBERTo	base (150M)	0,8926	0,7220	**0,5774**
NorBERTo	large (395M)	**0,9191**	**0,7689**	**0,5774**

- O **NorBERTo-large** supera o BERTimbau-large em todas as tarefas (+3,2 pontos no MRPC e +1,4 no RTE e WNLI).
- O **NorBERTo-base** (150M) supera o BERTimbau-large (340M) no MRPC e no WNLI com menos da metade dos parâmetros.

Evidência 3: Tarefas de Classificação e Redes Sociais

- Otimização sistemática de hiperparâmetros (HPO com Optuna) em 4 bases brasileiras: **TweetSent-BR**, **Hate-BR**, **TuPy-E** e **FakeRecogna 2.0**.
- **Alta competitividade:** o NorBERTo-large empata tecnicamente com o melhor modelo multilíngue (XLM-RoBERTa-large) em detecção de notícias falsas (**98,3% vs. 98,4%** no FakeRecogna 2.0) e discurso de ódio (**92,1% vs. 93,0%** no Hate-BR).
- **Onde outros modelos lideram:** o XLM-RoBERTa-large vence no TweetSent-BR (79,5%) e o BERTimbau lidera na classificação multiclasse do TuPy-E (90,8%).
- Os resultados sustentam uma abordagem de "caixa de ferramentas" (*toolbox*), escolhendo o encoder conforme o domínio.

Fonte: Silva et al. (PROPOR 2026), seção 5 e Apêndice A, Tabela 9.

Conclusão e limites da evidência

- Combinar o corpus massivo Aurora-PT (331B tokens) com a arquitetura ModernBERT eleva o estado da arte em inferência textual e no benchmark PLUE em português.
- O modelo viabiliza aplicações reais de *right-sized AI* e leitura de documentos longos (até 8.192 tokens) sem truncamento, ideal para pipelines de RAG.
- **Limite de escala no pré-treino:** os 226B de tokens efetivos ainda estão abaixo da escala de trilhões de tokens usada no ModernBERT original em inglês.
- **Limite em similaridade e avaliação:** o treino do zero reduziu a correlação de similaridade no ASSIN 2, e os testes atuais ainda não avaliam tarefas de contexto longo em português.

Fonte: Silva et al. (PROPOR 2026), seções 4.2.1, 5 e Limitations; análise crítica da equipe.

Artigo de referência

NorBERTo: A ModernBERT Model Trained for Portuguese with 331 Billion Tokens Corpus

Enzo S. N. Silva; Pablo B. Costa; Raphael C. Vlasman; Rosimeire P. Costa; Henrique L. P. Silva; Lucas F. A. O. Pellicer; Guilherme Rinaldo; Renato A. Almeida; Darian S. R. Rabbani; Cinthya O. Oestreich; Vinicius F. Caridá. Itaú Unibanco e ICTi. *Proceedings of the 17th International Conference on Computational Processing of Portuguese (PROPOR 2026)*, Salvador, Brasil, 2026.

Síntese baseada no PDF fornecido pela disciplina. Os dados e tabelas dos slides reproduzem as estatísticas do corpus Aurora-PT e os experimentos das Tabelas 1 a 9 do artigo.