

From Tokens to Words: On the Inner Lexicon of LLMs



João Victor
Lucas Rapozo
Antonieli Magalhães



O problema: palavras chegam fragmentadas

Exemplo de divisão artificial usado no artigo

cats $\longrightarrow$ ca + ts

- O tokenizador converte o texto em unidades que podem ser menores que uma palavra.
- Uma palavra fora do vocabulário de tokens únicos ainda pode ser representada por vários tokens.
- **Pergunta:** o modelo reconstrói internamente a palavra inteira? Onde e como isso acontece?


Fonte: Kaplan et al. (ICLR 2025), seções 1 e 4.1.

Hipótese: um léxico além do tokenizador

- **Vocabulário do tokenizador:** unidades com identificadores e vetores de entrada próprios.
- **Léxico interno:** representações de palavras que emergem nos cálculos do modelo, inclusive palavras de vários tokens.
- **Local proposto:** o estado interno do último token concentra informação sobre a palavra completa.
- O estudo investiga Llama2-7B, Llama3-8B, Mistral-7B e Yi-6B; os resultados destacados a seguir são do Llama2-7B.

Fonte: Kaplan et al. (ICLR 2025), seções 2–4; léxico distribuído, não um dicionário literal.

Mecanismo proposto: agregar e reconstruir



1. **Atenção:** reúne informações dos fragmentos no último token.
2. **FFNs:** redes de cada camada contribuem para reconstruir a representação da palavra.

À direita, o vetor extraído é inserido em outro contexto para testar a recuperação da palavra.

Fonte: Kaplan et al. (ICLR 2025), Figura 1, reproduzida do artigo; seção 5.

Evidência 1: palavras versus não palavras

- Conjunto balanceado: 10 mil palavras em inglês e não palavras construídas por embaralhamento de tokens.
- Um classificador k-NN tenta distinguir os grupos usando os estados internos de cada camada.
- **Último token:** pico de **89% de acurácia na camada 13**.
- **Controle com o penúltimo token:** chega a 61%, em palavras de três tokens ou mais.

Fonte: Kaplan et al. (ICLR 2025), seção 3 e Figura 2; acurácia do classificador auxiliar, não do LLM em tarefas gerais.

Evidência 2: recuperar a palavra inteira

Experimento	Como verificar	Resultado no Llama2-7B
Palavra de um token, dividida artificialmente	Comparar o estado interno com os vetores de entrada (logit lens adaptado).	93,2% recuperadas em pelo menos uma camada.
Palavra originalmente de vários tokens	Inserir o vetor em outro prompt e pedir repetição (Patchscopes).	77,4% recuperadas em pelo menos uma camada.

Limite: 22,6% das palavras de vários tokens não foram recuperadas por esse procedimento em nenhuma camada.

Fonte: Kaplan et al. (ICLR 2025), seções 4.1 e 4.2; taxas acumuladas entre camadas, não acurácia de uma única camada.

Evidência 3: intervir nas redes FFN

- Os autores removem atualizações FFN associadas à palavra completa, em cerca de 5% das camadas.
- Em palavras com sufixos divididas artificialmente, a recuperação cai de **85% para 18%**.
- Remover a mesma quantidade de atualizações aleatórias tem pouco ou nenhum efeito nesse teste.
- A intervenção reforça o papel das FFNs no mecanismo, além da observação de semelhanças entre vetores.

Fonte: Kaplan et al. (ICLR 2025), seção 5.1; ablação em palavras com sufixos ing, ion e est.

Aplicação: ampliar o vocabulário

1. Extrair a representação de uma palavra de vários tokens na primeira camada em que ela é recuperada.
2. Aprender projeções para gerar suas novas entradas nas matrizes de entrada e saída.
3. Refinar as novas representações com matrizes adicionais, mantendo os demais parâmetros congelados.

Distinção importante: os pesos centrais ficam fixos, mas há aprendizado de projeções e treinamento de refinamento.

Fonte: Kaplan et al. (ICLR 2025), seção 6 e Figura 6; “sem fine-tuning” não significa ausência de treinamento auxiliar.

Menos tokens, acurácia próxima da original

Expansão do vocabulário no Llama2-7B

Conjunto	Original	Método	Menos tokens
WikiText-103	52,2%	51,9%	10,5%
PubMed	51,7%	51,1%	13,5%
Wiki40B em árabe	53,5%	53,2%	14,5%

- Original e Método: acurácia top-1 em nível de token, na linha geral da Tabela 1.
- Redução medida na codificação do texto; não equivale a uma redução comprovada de igual valor na latência.

Fonte: Kaplan et al. (ICLR 2025), Tabela 1 e Apêndice H, Tabela 5.

Conclusão e limites da evidência

- Os experimentos sustentam a reconstrução de palavras no último token, sobretudo em camadas iniciais e intermediárias.
- As representações podem ampliar o vocabulário e reduzir o número de tokens processados.
- Recuperar uma palavra não comprova compreensão semântica completa; falhar na recuperação não prova ausência de conhecimento.
- A aplicação foi avaliada no Llama2-7B em três conjuntos. Generalização e ganhos de tempo exigem avaliações adicionais.

Fonte: Kaplan et al. (ICLR 2025), seções 4–7 e Apêndice H; limites interpretativos destacados pela equipe.

Artigo de referência

From Tokens to Words: On the Inner Lexicon of LLMs

Guy Kaplan; Matanel Oren; Yuval Reif; Roy Schwartz.

The Hebrew University of Jerusalem. *ICLR 2025*.

arXiv:2410.05864v4, versão de 3 de março de 2025.

Código: schwartz-lab-NLP/Tokens2Words

Conclusão baseada no PDF fornecido. A Figura 1 foi reproduzida do artigo; tabelas dos slides são recortes dos resultados, com identificação da métrica e do experimento.